

Formális nyelvek - 3.

Csuhaj Varjú Erzsébet

Algoritmusok és Alkalmazásaik Tanszék
Informatikai Kar
Eötvös Loránd Tudományegyetem
H-1117 Budapest
Pázmány Péter sétány 1/c
E-mail: csuhaj@inf.elte.hu

Környezetfüggetlen grammatikák normálformái

Grammatikai transzformációkkal nyert grammatikák,

- melyek bizonyos szintaktikai feltételeknek vagy **tulajdonságoknak** tesznek eleget,
- általában valamilyen szempontból egyszerűbbek, mint az eredeti grammatikák,
- de **ugyanazon típusba** tartoznak,
- és **ugyanazt a nyelvet generálják**.

Tétel (ε -mentesítés)

Minden $G = (N, T, P, S)$ **környezetfüggetlen grammatikához** meg tudunk konstruálni egy **vele ekvivalens** $G' = (N', T, P', S')$ **környezetfüggetlen grammatikát** úgy, hogy

- G' minden szabályának jobboldala **nemüres szó**,
- **kivéve** azt az esetet, ha az **üres szó benne van a G által generált nyelvben**,
- mely esetben $S' \rightarrow \varepsilon$ az **egyetlen** olyan szabály, melynek jobboldala az üres szó és ekkor S' **nem fordul elő** a G' egyetlen szabályának jobboldalán sem.

Bizonyításvázlat:

Tekintsük a $G = (N, T, P, S)$ környezetfüggetlen grammatikát. Ha P nem tartalmaz $X \rightarrow \varepsilon$ alakú szabályt, akkor $G' = G$.

Tegyük fel, hogy P -ben van $X \rightarrow \varepsilon$ alakú szabály. Definiáljuk az $U_i \subseteq N$ halmazokat a következőképpen:

$$U_1 = \{X \mid X \rightarrow \varepsilon \in P\},$$

$$U_{i+1} = U_i \cup \{X \mid X \rightarrow u \in P \text{ és } u \in U_i^*\}, \quad i \geq 1.$$

Nyilvánvaló, hogy az U_i sorozat, $i = 1, 2, \dots$, a tartalmazásra nézve hierarchiát alkot és van olyan k index, hogy $U_k = U_{k+1}$ és így $U_k = U_j$ minden $j \geq k$ -ra.

Legyen $U = U_k$.

Ekkor azonnal látható, hogy $X \Rightarrow_G^* \varepsilon$ akkor és csak akkor, ha $X \in U$.

(Vagyis, $\varepsilon \in L(G)$ akkor és csak akkor, ha $S \in U$.)

Bizonyításvázlat - folytatás:

Ezután megkonstruáljuk a P_1 szabályhalmazt a következőképpen:

Minden olyan $X \rightarrow u$ szabály benne van P_1 -ben, amelyre $u \neq \varepsilon$ és van olyan $v \in (N \cup T)^*$ sztring, hogy $X \rightarrow v \in P$ és u -t v -ből úgy kapjuk meg, hogy U -beli nemterminálisok valahány, azaz nulla vagy több előfordulását elhagyjuk v -ből. P_1 -ben nincs más szabály.

(**Példa:** Legyen $A, B \in U$ és $C \notin U$, akkor az $S \rightarrow ACAB$ szabályból a következő szabályokat képezzük: $S \rightarrow ACAB$, $S \rightarrow CAB$, $S \rightarrow ACB$, $S \rightarrow ACA$, $S \rightarrow CB$, $S \rightarrow CA$, $S \rightarrow AC$, $S \rightarrow C$.)

Legyen $G_1 = (N, T, P_1, S)$. Ekkor látható, hogy $L(G_1) \subseteq L(G) - \{\varepsilon\}$, hiszen minden $X \rightarrow u$ szabály alkalmazása megfelel az $X \rightarrow v$ szabály alkalmazásának, amelyet valahány $Z \Rightarrow_G^* \varepsilon$ levezetés alkalmazásával kombinálunk, ahol $Z \in U$ és Z előfordul v -ben.

Megfordítva, ha $S \Rightarrow_G^* u$ és $u \neq \varepsilon$, akkor $S \Rightarrow_{G_1}^* u$, hiszen az $X \rightarrow \varepsilon$ típusú szabályok alkalmazása elkerülhető P_1 megfelelő szabályának alkalmazásával.

Bizonyításvázlat - folytatás:

A fentiek alapján $L(G_1) = L(G) - \{\varepsilon\}$. Ha $\varepsilon \notin L(G)$, akkor $G' = G_1$.

Ha $\varepsilon \in L(G)$, akkor vesszük a $G' = (N \cup \{S'\}, T, P_1 \cup \{S' \rightarrow \varepsilon, S' \rightarrow S\}, S')$ grammatikát, amely az $L(G)$ nyelvet generálja.

ε -mentes grammatika

Definíció

A G grammatikát **ε -mentesnek** nevezzük, ha egyetlen szabályának jobboldala sem az üres szó.

Tétel

Minden környezetfüggetlen G grammatikához meg tudunk konstruálni egy G' ε -mentes környezetfüggetlen grammatikát, amelyre $L(G') = L(G) - \{\varepsilon\}$ teljesül.

Az állítás közvetlen következménye a megelőző állításnak, az előző bizonyításban konstruált G_1 grammatika pontosan ilyen.

Környezetfüggetlen grammatikák Chomsky-normálformája

Definíció

A $G = (N, T, P, S)$ környezetfüggetlen grammatikát **Chomsky-normálformájúnak** mondjuk, ha minden egyes szabálya vagy

1. $X \rightarrow a$, ahol $X \in N$, $a \in T$, vagy
2. $X \rightarrow YZ$, ahol $X, Y, Z \in N$ alakú.

Chomsky-normálforma - folytatás:

Tétel:

Minden ε -mentes $G = (N, T, P, S)$ környezetfüggetlen grammatikához meg tudunk konstruálni egy vele **ekvivalens** $G' = (N', T, P', S)$ **Chomsky-normálformájú** környezetfüggetlen grammatikát.

Bizonyításvázlat:

Ha minden szabály $X \rightarrow a$ vagy $X \rightarrow YZ$ alakú, ahol $a \in T$, $X, Y, Z \in N$, akkor $G' = G$. Ha nem, akkor a következőképpen járunk el.

Az általánosság megszorítása nélkül feltehetjük, hogy a P szabályhalmaz elemei terminális szimbólumokat csak az $X \rightarrow a$, $a \in T$ alakú szabályokban tartalmaznak (egy megelőző normálforma tételhez hasonlóan járunk el). Ebben az esetben minden további szabály $X \rightarrow u$ alakú, ahol $u \in N^+$.

3) Ekkor minden

$$X \rightarrow Y_1 Y_2 \dots Y_k, \quad k \geq 3$$

alakú szabályt helyettesítünk egy

$$\begin{aligned} X &\rightarrow Y_1 Z_1, \\ Z_1 &\rightarrow Y_2 Z_2, \\ &\dots, \\ Z_{k-2} &\rightarrow Y_{k-1} Y_k, \end{aligned}$$

szabályhalmazzal, ahol Z_1, \dots, Z_{k-2} új, a szabályhoz bevezetett nemterminálisok.

Bizonyításvázlat - folytatás:

Így egy $G_1 = (N', T, P_1, S)$ grammatikát kapunk, ahol P_1 olyan szabályokból áll, amelyek alakja az alábbi három típus valamelyike:

1. $X \rightarrow a, X \in N', a \in T,$
2. $X \rightarrow Y, X, Y \in N',$
3. $X \rightarrow YZ, X, Y, Z \in N'.$

Az N' halmaz N elemeiből, valamint azokból az új nemterminálisokból áll, amelyeket külön-külön bevezettünk P azon szabályaihoz, amelyek jobboldalának hosszát csökkentettük.

Bizonyításvázlat - folytatás:

Könnyű belátni, hogy a $L(G_1) = L(G)$.

Legyen $S = u_1 \Rightarrow u_2 \dots \Rightarrow^* u_m = u$ levezetés G -ben, ahol $u \in T^*$ és $u_j \in (N \cup T)^*$, $1 \leq j \leq m - 1$.

Akkor az $u_i \Rightarrow u_{i+1}$, $1 \leq i \leq m - 1$, közvetlen levezetési lépésben P valamely szabályát alkalmazzuk.

Ha a szabály $X \rightarrow a$, vagy $X \rightarrow Y$, vagy $X \rightarrow YZ$ alakú, akkor a közvetlen levezetési lépés megfelel egy közvetlen levezetési lépésnek G_1 -ben.

Ha valamely $X \rightarrow Y_1 Y_2 \dots Y_k$, $k \geq 3$ alakú szabályt alkalmazzuk, akkor a megelőzőek alapján létezik G_1 -ben egy $u_i \Rightarrow^* u_{i+1}$ levezetés, amely megfelel a szabály alkalmazásának. Így $L(G) \subseteq L(G_1)$.

$L(G_1) \subseteq L(G)$ is fennáll, mivel minden $X \rightarrow Y_1 Y_2 \dots Y_k$, $k \geq 3$ alakú szabályhoz új, szabályonként különböző nemterminálisokat vezettünk be, vagyis nem fordulhat elő olyan eset, hogy a szabályok alkalmazása közben olyan mondatforma is megjelenik, amely nem vezet $L(G)$ -beli szóra.

Vagyis, $L(G_1) = L(G)$.

Bizonyításvázlat - folytatás:

A továbbiakban az $X \rightarrow Y$ **alakú** szabályokat, ahol X és Y nemterminálisok, és amelyeket **láncszabályoknak nevezünk**, elimináljuk a szabályhalmazból.

Ezen célból minden egyes $X \in N'$ nemterminálisra definiáljuk az $U_i(X)$ halmazokat a következőképpen:

$$U_1(X) = \{X\},$$

$$U_{i+1}(X) = U_i(X) \cup \{Y \mid Y \rightarrow Z \in P_1, Z \in U_i(X)\}, \quad i = 1, 2, \dots$$

Nyilvánvaló, hogy van olyan k természetes szám, hogy $U_k(X) = U_{k+1}(X)$, és így $U_k(X) = U_l(X)$ teljesül minden l -re, ahol $l \geq k$.

Legyen $U_k(X) = U(X)$.

Látható, hogy $Y \Rightarrow^* X$ akkor és csak akkor, ha $Y \in U(X)$.

Bizonyításvázlat - folytatás:

Definiáljuk P' -t a következőképpen:

1. $X \rightarrow a \in P'$ akkor és csak akkor, ha van olyan $A \in N'$, ahol $X \in U(A)$ és $A \rightarrow a \in P_1$,
2. $X \rightarrow YZ \in P'$ akkor és csak akkor, ha van olyan $A \in N'$, ahol $X \in U(A)$ és $A \rightarrow YZ \in P_1$.

További szabály nincs P' -ben.

Látható, hogy $X \rightarrow a \in P'$ akkor és csak akkor, ha $X \Rightarrow_{G_1}^* a$ és $X \rightarrow YZ \in P'$ akkor és csak akkor, ha $X \Rightarrow_{G_1}^* A \Rightarrow_{G_1}^* YZ$ teljesül valamely A -ra.

Ezek alapján megmutatható, hogyha egy terminális szó generálható a G_1 grammatikával, akkor generálható a G' grammatikával is, és a fordított állítás is fennáll. Vagyis, $L(G) = L(G')$.

Következmények:

Tétel: (szóprobléma)

Minden $G = (N, T, P, S)$ környezetfüggetlen grammatika esetében eldönthető, hogy egy tetszőleges $u \in T^*$ szó benne van-e G grammatika által generált nyelvben vagy sem.

Bizonyításvázlat:

Mivel az előzőek alapján az, hogy az üres szó benne van-e a G grammatika által generált nyelvben eldönthető, elég az $u \neq \varepsilon$ esetre szorítkozni. Az általánosság megszorítása nélkül feltehetjük, hogy G Chomsky-normálformájú. Ekkor az u szó $k = 2|u| - 1$ lépésben levezethető G -ben ($|u|$ az u szó hosszát jelöli). (Lásd a G szabályainak alakját). Minthogy a G grammatikában a legfeljebb k lépésben levezethető szavak véges halmazt alkotnak, ezért el tudjuk dönteni, hogy u előfordul-e ebben a halmazban vagy sem.

Következmények:

Korollárium:

Minden $G = (N, T, P, S)$ környezetfüggetlen grammatika és minden $L \subseteq T^*$ véges nyelv esetében eldönthető, hogy igazak-e a következő állítások: $L \subseteq L(G)$, valamint $L \cap L(G) = \emptyset$.