

Formális nyelvek és automaták

vizsga jegyzet

Szerkesztette: Szabó Dániel

2014. június 5.



Ez a Mű a [Creative Commons Nevezd meg! - Ne add el! - Így add tovább! 2.5 Magyarország Licenc](https://creativecommons.org/licenses/by-nc-sa/2.5/hu/) feltételeinek megfelelően felhasználható.

1. feladathoz való fogalmak:

- ϵ : A 0 hosszúságú sorozatot üres szónak nevezzük és ϵ -al jelöljük.
- V^* : A V abc feletti szavak halmazát beleértve az üres szót is V^* -al jelöljük.
- V^+ : A V abc feletti nem üres szavak halmazát V^+ -al jelöljük
- **Részszó:** Legyen V abc és legyenek u és v szavak V felett. Az u szót a v szó részszávának nevezzük, ha $v = xuy$ teljesül valamely x és y V feletti szavakra. Az u szót a v szó valódi részszávának mondjuk, ha $u \neq v$ és $u \neq \epsilon$.
- **Prefix, Szufix:** Legyen V abc és legyenek u, v, x, y szavak V felett, továbbá legyen $v = xuy$. Ha $x = \epsilon$, akkor u -t a v szó prefixének vagy kezdőszeletének, ha $y = \epsilon$, akkor u -t a v szó szufixének vagy utótagjának hívjuk.
- **Szó hossza:** A w szó hosszán a w szót alkotó szimbólumok számát értjük (azaz, w mint sorozat hosszát) és $|w|$ -vel jelöljük.
- **Szó i -edik hatványa (0. első i -edik):** Legyen i nem negatív egész szám és legyen w a V abc feletti szó ($w \in V^*$). A w szó i -edik hatványa alatt a w szó i példányának konkatenáltját értjük és w^i -vel jelöljük. Konvenció alapján minden $w \in V^*$ szóra $w^0 = \epsilon$.
- **Tükörkép:** Legyen u egy V abc feletti szó. Az u szó tükörképe vagy fordítottja alatt azt a szót értjük, amelyet úgy kapunk, hogy u szimbólumait megfordított sorrendben írjuk. Az u szó tükörképét u^{-1} -gyel jelöljük.
- **Levezetés:** Legyen $G = (N, T, P, S)$ egy generatív grammatika és legyen $u, v \in (N \cup T)^*$. Azt mondjuk, hogy a v szó k lépésben levezethető az u szóból G -ben, $k \geq 1$, ha létezik olyan $u_1, \dots, u_{k+1} \in (N \cup T)^*$ szavakból álló sorozat, amelyre $u = u_1$, $v = u_{k+1}$, valamint $u_i \Rightarrow_G u_{i+1}$, $1 \leq i \leq k$ teljesül. A v szó levezethető az u szóból G -ben, ha vagy $u = v$, vagy létezik olyan $k \geq 1$ szám, hogy a v szó az u szóból k lépésben levezethető.
- **Közvetlen Levezetés:** Legyen $G = (N, T, P, S)$ egy generatív grammatika és legyen $u, v \in (N \cup T)^*$. Azt mondjuk, hogy a v szó közvetlenül vagy egy lépésben levezethető az u szóból G -ben és ezt $u \Rightarrow_G v$ módon jelöljük, ha $u = u_1xu_2$, $v = u_1yu_2$, $u_1, u_2 \in (N \cup T)^*$ és $x \rightarrow y \in P$.
- **Konkatenáció:** Legyen V egy abc és legyenek u, v V feletti szavak (azaz, legyen $u, v \in V^*$). Az uv szót az u és v szavak konkatenáltjának nevezzük. PL: Legyen az abc $V = \{a, b, c\}$, legyenek $u = abb$ és $v = cbb$ szavak. Akkor $uv = abbcbb$ az u és v konkatenáltja. A konkatenáció mint művelet asszociatív, de általában nem kommutatív.
- **Reguláris műveletek:** Az unió, a konkatenáció, valamint a lezáras (a^*) műveleteket együttesen reguláris műveleteknek nevezzük.
- **Nyelv:** Legyen V abc és legyen L tetszőleges részhalmaza V^* -nak. Akkor L -et egy V feletti nyelvnek nevezzük. Az üres nyelv - amely egyetlen szót sem tartalmaz - jelölése \emptyset . Egy nyelvet véges nyelvnek mondunk, ha véges számú szót tartalmaz, ellenkező esetben végtelen nyelvről beszélünk.
- **Üres Nyelv \emptyset :** Nem üres, tartalmazza az epszilont.
- **De-Morgan:**
- **Asszociatív:**
- **Distributív:**

2. feladathoz való fogalmak: (Generatív grammatikák)

- **Mit nevezünk generatív grammatikának:**
 - o Egy G generatív grammatikán (grammatikán vagy (generatív) nyelvtanon) egy (N, T, P, S) négyest értünk, ahol:
 - N és T diszjunkt abc-k, a nemterminális és a terminális szimbólumok abc-i
 - $S \in N$ a kezdőszimbólum (axióma)
 - P véges halmaza (x, y) rendezett pároknak, ahol $x, y \in (N \cup T)^*$ és x legalább egy nemterminális szimbólumot tartalmaz. A P halmaz elemeit átírási szabályoknak (röviden szabályoknak) vagy produkcióknak nevezzük. Az (x, y) jelölés helyett használhatjuk az $x \rightarrow y$ jelölést is, ahol $a \rightarrow$ szimbólum nem eleme az $(N \cup T)$ halmaznak.
- **Levezethetőséggel kapcsolatos fogalmak:** LSD 1. feladat szabályok.
- **Generált nyelv:** Legyen $G = (N, T, P, S)$ egy tetszőleges generatív grammatika. A G grammatika által generált $L(G)$ nyelv alatt az $L(G) = \{w \mid S \Rightarrow_G^* w, w \in T^*\}$ szavakból álló halmazt értjük. Azaz, a G grammatika által generált nyelv a T^* halmaz azon elemei, amelyek levezethetők a G grammatika S kezdőszimbólumából.
- **Ekvivalencia:** Két generatív grammatikát ekvivalensnek nevezünk, ha ugyanazt a nyelvet generálják, gyengén ekvivalensnek, ha legfeljebb az üres szóban különböznek.
- **1,2,3 as típusu grammatika:**
 - o A $G = (N, T, P, S)$ generatív grammatikát i -típusúnak mondjuk, ($i = 0, 1, 2, 3$) ha P szabályhalmazára teljesülnek a következők:
 - $i = 0$: Nincs korlátozás.
 - $i = 1$: P minden szabálya $u_1 A u_2 \rightarrow u_1 v u_2$ alakú, ahol $u_1, u_2, v \in (N \cup T)^*$ és $A \in N$, és $v \neq \epsilon$, kivéve az $S \rightarrow \epsilon$ alakú szabályt, feltéve, hogy P -ben ilyen szabály létezik. Ha P tartalmazza az $S \rightarrow \epsilon$ szabályt, akkor S nem fordul elő P egyetlen szabályának jobboldalán sem.
 - $i = 2$: P minden szabálya $A \rightarrow v$ alakú, ahol $A \in N$ és $v \in (N \cup T)^*$
 - $i = 3$: P minden szabálya vagy $A \rightarrow uB$ vagy $A \rightarrow u$, alakú, ahol $A, B \in N$ és $u \in T^*$.
- **Mondat szerkezetű (rekurzívan felsorolható) grammatika:** A 0-s típusú grammatikát rekurzívan felsorolható, mondat szerkezetű grammatikának is mondjuk.
- **Környezet függő Grammatika:** Az 1-típusú grammatikát környezet függő grammatikának is mondjuk.
- **Környezet független Grammatika:** A 2-típusú grammatikát környezet független grammatikának is mondjuk.
- **Reguláris grammatika:** A 3-típusú grammatikát reguláris vagy véges állapotú grammatikának is mondjuk.
- **Mikor aktív egy nem terminális szimbólum:** A környezetfüggetlen grammatika egy nemterminálisát inaktívnak vagy nem aktívnak nevezzük, ha nem vezethető le belőle terminális szó; egyébként aktívnak mondjuk.
- **Mikor elérhető egy nem terminális szimbólum:** A környezetfüggetlen grammatika egy nemterminálisát nem elérhetőnek nevezzük, ha nem fordul elő egyetlen olyan mondatformában sem, amely a kezdőszimbólumból levezethető; egyébként elérhetőnek mondjuk.
- **Mikor hasznos egy nem terminális szimbólum:** Egy nemterminális nem hasznosnak mondunk, ha vagy inaktív, vagy nem elérhető, vagy mindkét tulajdonság teljesül esetében. Egy nemterminális hasznosnak nevezzük, ha aktív és elérhető.
- **Redukált grammatika jelentése:** Egy környezetfüggetlen grammatika redukált, ha minden nemterminálisa aktív és elérhető.

3. feladathoz való fogalmak: (Reguláris nyelvek)

- **Chomsky normálforma fogalma:** $A G = (N, T, P, S)$ környezetfüggetlen grammatikát
- Chomsky-normálformájúnak mondjuk, ha minden egyes szabálya vagy:
 - o $X \rightarrow a$, ahol $X \in N$, $a \in T$, vagy
 - o $X \rightarrow YZ$, ahol $X, Y, Z \in N$ alakú
- **Reguláris kifejezés fogalma:** Legyenek V és $V' = \{\epsilon, \cdot, +, *, (,)\}$ diszjunkt abc-k. A $V \cup V'$ abc feletti reguláris kifejezéseket rekurzív módon a következőképpen definiáljuk:
 - o ϵ reguláris kifejezés V felett.
 - o Minden $a \in V$ reguláris kifejezés V felett.
 - o Ha R reguláris kifejezés V felett, akkor $(R)^*$ is reguláris kifejezés V felett.
 - o Ha Q és R reguláris kifejezések V felett, akkor $(Q) \cdot (R)$ és $(Q) + (R)$ is reguláris kifejezések V felett.

A reguláris kifejezések az L_3 nyelvosztályt a grammatikáktól eltérően határozzák meg; megadunk formulák egy osztályát, ahol minden formula egy nyelvet jelöl, és megmutatjuk, hogy a formulák által jelölt nyelvek családja L_3 .

- **Lineáris grammatika fogalma:** Egy $G = (N, T, P, S)$ környezetfüggetlen grammatikát lineárisnak nevezünk, ha minden szabálya vagy
 - o $A \rightarrow u$, $A \in N$, $u \in T^*$ vagy
 - o $A \rightarrow u_1 B u_2$ alakú, ahol $A, B \in N$ és $u_1, u_2 \in T^*$
- **Lezártak fogalma:** Az L nyelv az lezártja (Kleene-lezártja) alatt az $L^* = \bigcup_{i \geq 0} L^i$ nyelvet értjük. A megfelelő műveletet lezárásnak vagy $*$ műveletnek mondjuk. Az L^+ nyelv alatt az $L^+ = \bigcup_{i \geq 1} L^i$ nyelvet értjük. Nyilvánvalóan, ha $\epsilon \in L$, akkor $L^+ = L^*$.

Legyen V egy abc és legyenek L_1, L_2 nyelvek V felett ($L_1 \subseteq V^*$ és $L_2 \subseteq V^*$).

- **Reguláris nyelvek metszete:** $L_1 \cap L_2 = \{u \mid u \in L_1 \text{ és } u \in L_2\}$ - az L_1 és az L_2 nyelv metszete.
- **Reguláris nyelvek uniója:** $L_1 \cup L_2 = \{u \mid u \in L_1 \text{ vagy } u \in L_2\}$ - az L_1 és az L_2 nyelv uniója
- **Reguláris nyelvek konkatenáltja:** $L_1 L_2 = \{u_1 u_2 \mid u_1 \in L_1, u_2 \in L_2\}$ - az L_1 és az L_2 nyelv konkatenációja.
- **Reguláris nyelvek különbsége:** $L_1 - L_2 = \{u \mid u \in L_1 \text{ és } u \notin L_2\}$ - az L_1 és az L_2 nyelv különbsége.
- **Reguláris nyelvek tükörképe:** $L^{-1} = \{u^{-1} \mid u \in L\}$ a tükörképe (megfordítása) az L nyelvnek. $(L^{-1})^{-1} = L$ és $(L^{-1})^i = (L^i)^{-1}$, $i \geq 0$.
- **Reguláris nyelvek komplemente:** Az $L \subseteq V^*$ nyelv komplemente a V abc-re vonatkozóan L felül vonás $= V^* - L$.
- **i-edik hatvány:** L^i jelöli az L nyelv i -edik hatványát, ahol $i \geq 0$. ($L^0 = \{\epsilon\}$, $L^n = L^{n-1} L$, $n \geq 1$.)
- Minden L nyelvre fennállnak a következő egyenlőségek: $\emptyset L = L \emptyset = \emptyset$ és $\{\epsilon\} L = L \{\epsilon\} = L$.
- **Homomorfizmus:** A $h : V_1^* \rightarrow V_2^*$ leképezést homomorfizmusnak nevezzük, ha $h(uv) = h(u)h(v)$ minden $u, v \in V_1^*$ esetén. A fenti tulajdonság alapján $h(\epsilon) = \epsilon$. (Minden $u \in V_1^*$ -ra $h(u) = h(\epsilon u) = h(u\epsilon)$.)
- **Izomorfizmus:** A h homomorfizmust izomorfizmusnak nevezzük, ha bármely u és v V_1^* -beli szóra teljesül, hogyha $h(u) = h(v)$, akkor $u = v$.

4. feladathoz való fogalmak: (Véges automaták)

- **Determinisztikus automata fogalma:** A (determinisztikus) véges automata egy rendezett ötös, $A = (Q, T, \delta, q_0, F)$
 - o ahol Q állapotok véges nem üres halmaza,
 - o T input szimbólumok abc-je
 - o δ egy leképezés, az ún. állapot-átmeneti (röviden átmeneti) függvény a $Q \times T$ halmazból a Q halmazba,
 - o $q_0 \in Q$ az ún. kezdeti állapot (kezdő állapot)
 - o $F \subseteq Q$ az ún. elfogadó állapotok halmaza.

Szokás az elfogadó állapot helyett végállapotot is mondani.

A δ függvény egyértékű, ezért minden egyes (q,a) párra, ahol $(q,a) \in Q \times T$ egyetlen olyan p állapot létezik, amelyre $\delta(q,a) = p$ teljesül. Ezért ezt a véges automata't determinisztikusnak nevezzük.

- **Nem determinisztikus automata fogalma:** Ha többértékű állapot-átmeneti függvényt is megengedünk, azaz δ a $Q \times T$ halmazból a 2^Q halmazba való leképezés, akkor nemdeterminisztikus véges automatáról beszélünk. Ebben az esetben aktuális állapotnak egy állapothalmaz valamely elemét, mintsem egyetlen állapotot tekinthetünk. Ez azt jelenti, hogy a kezdeti állapot helyettesíthető egy $Q_0 \subseteq Q$ kezdő állapothalmazzal (kezdeti állapothalmazzal). Az is előfordulhat, hogy egy a input szimbólum esetén $\delta(q,a)$ üres az aktuális állapotok mindegyikére.
- **Közvetlen lépés:** Legyen $A = (Q, T, \delta, Q_0, F)$ egy véges automata és legyenek $u, v \in QT^*$ szavak (ahol QT^* a Q és T^* konkatenációját jelöli). Azt mondjuk, hogy az A automata az u szót a v szóra redukálja egy lépésben vagy közvetlenül ($u \Rightarrow_A v$), ha van olyan $qa \rightarrow p$ szabály M_δ -ban (azaz, $\delta(q,a) = p$) és van olyan $w \in T^*$ szó, amelyre $u = qaw$ és $v = pw$ teljesül.
- **Redukció:** Az $A = (Q, T, \delta, Q_0, F)$ véges automata az $u \in QT^*$ szót a $v \in QT^*$ szóra redukálja ($u \Rightarrow_A^* v$), ha vagy $u = v$, vagy van olyan $z \in QT^*$, $u \Rightarrow_A^* z$ és $z \Rightarrow_A^* v$ teljesül. \Rightarrow_A^* reláció, valamint tranzitív és reflexív lezártja, \Rightarrow_A^* lényegében a grammatikák elméletéből ismert levezetésnek felel meg.
- **Összefüggőség:** Nem létezik olyan reguláris nyelv, amely nemdeterminisztikus véges automatával felismerhető, de nem ismerhető fel determinisztikus véges automatával

5. feladathoz való fogalmak: (Veremautomata)

- **Veremautomata fogalma, felépítése:**
 - o A veremautomata egy $A = (Z, Q, T, \delta, z_0, q_0, F)$ rendezett hetes, ahol
 - Z : a veremszimbólumok véges halmaza,
 - Q : az állapotok véges halmaza
 - T : az inputszimbólumok véges halmaza
 - δ : leképezése a $Z \times Q \times (T \cup \{\epsilon\})$ halmaznak $Z^* \times Q$ véges részhalmazába, az ún. átmeneti függvény,
 - $z_0 \in Z$ a kezdeti (kezdő) veremszimbólum
 - $q_0 \in Q$ a kezdeti (kezdő) állapot
 - $F \subseteq Q$ az elfogadó állapotok halmaza.
- **Veremautomata által elfogadott nyelv:**

6. feladathoz való fogalmak: (Bizonyítás)